

# Sensores espectroscópicos e modelos de regressão aplicados na análise de solos

## Aula 6 – Redes Neurais Convolucionais - parte 2

Me. José Vinícius Ribeiro



UNIVERSIDADE  
ESTADUAL DE LONDRINA



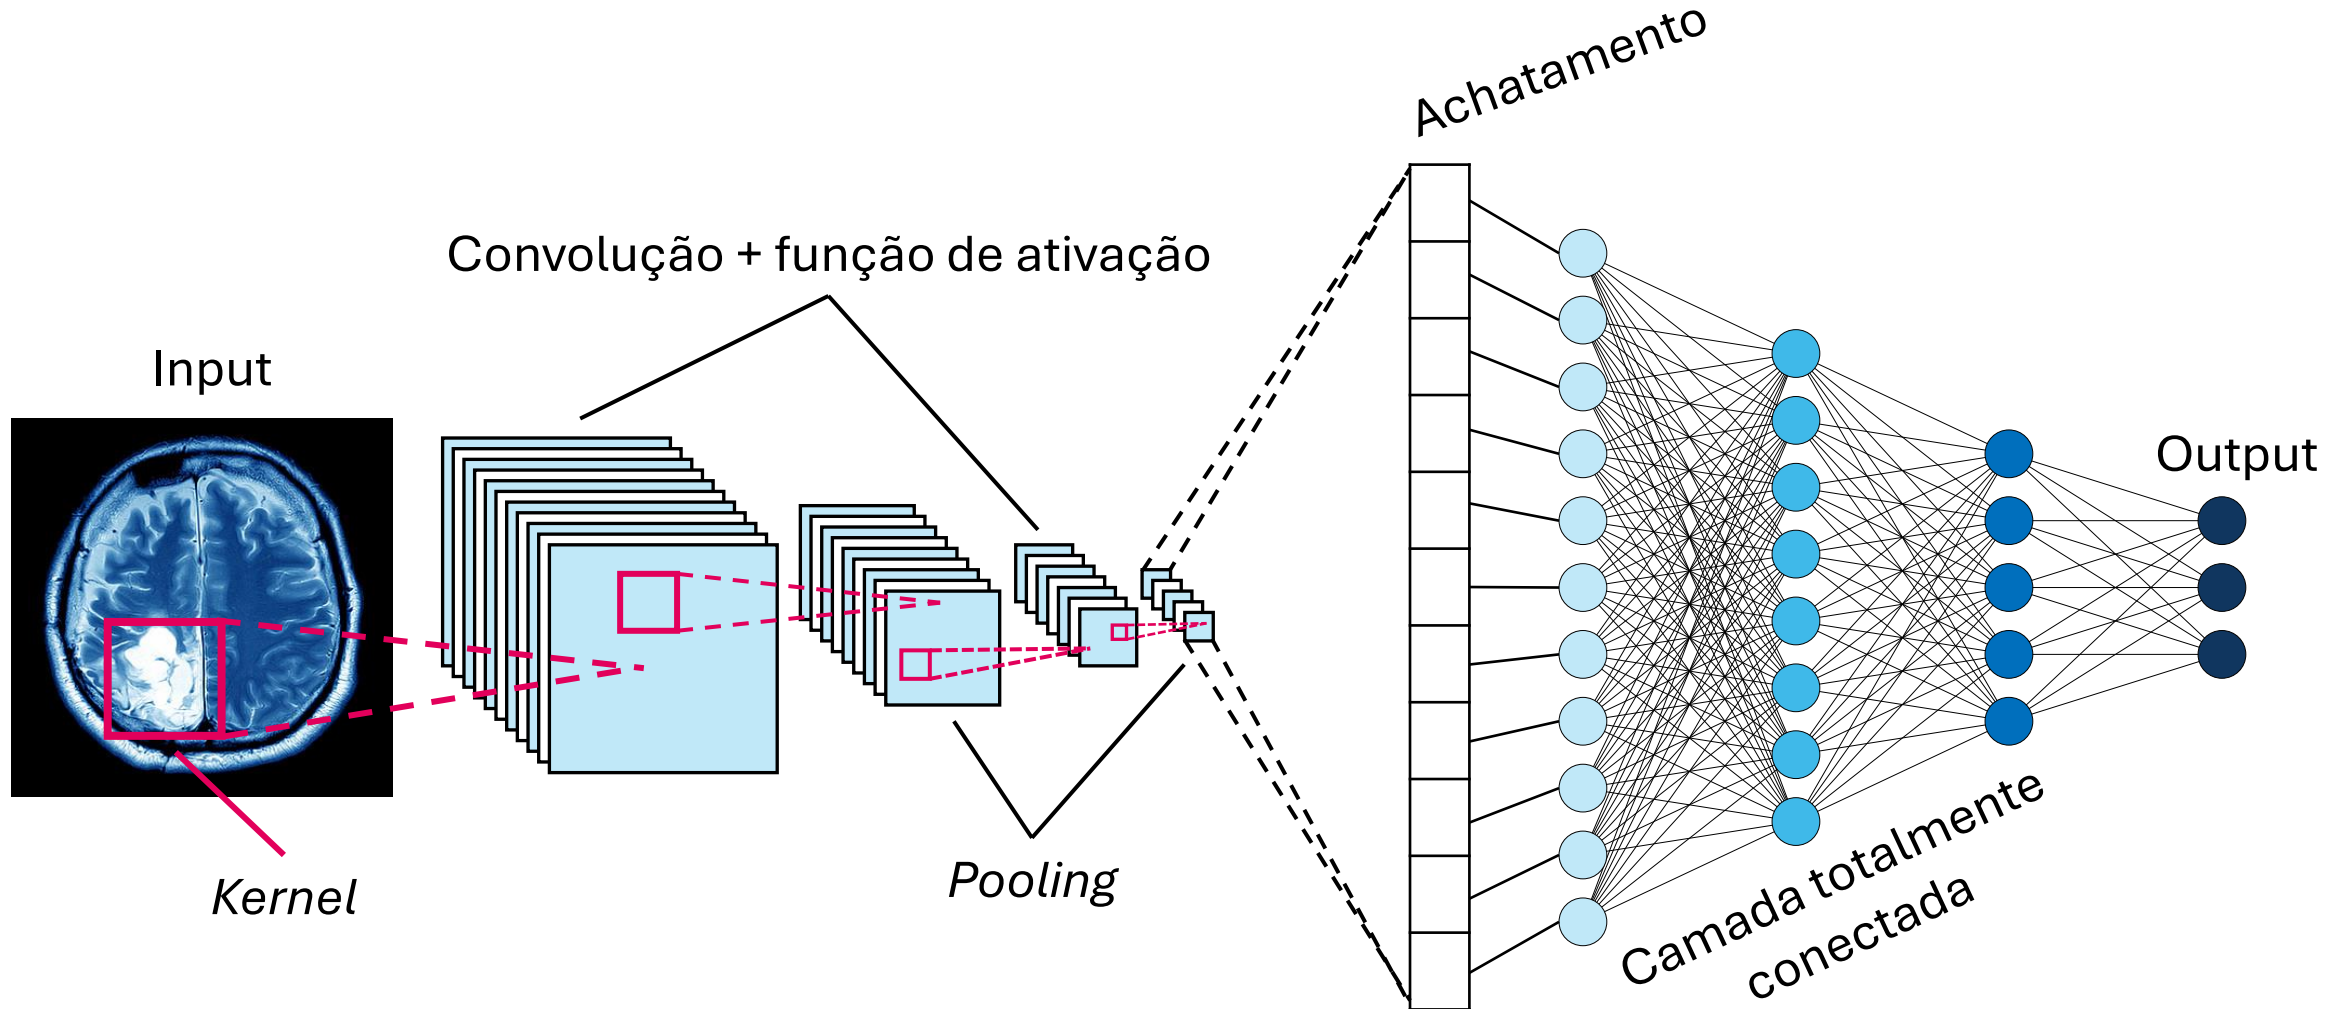
PÓS GRADUAÇÃO  
FÍSICA UEL

# SUMÁRIO

- Intuição por traz da Transformada de Fourier
- Transformada discreta de Fourier
- Transformada de Fourier de tempo curto
- CNN 2D – espectrogramas
- Prática no python (google colab)

# Relembrando a arquitetura básica



## Redes Neurais Convolucionais (CNN)





# Motivação

Como extrair todo o potencial da camada de convolução de uma CNN no contexto de dados espectrais 1D?

Uma possível saída é tratar os espectros como **séries temporais** e extrair a sua representação no **domínio das frequências**, gerando os **espectrogramas (2D)**. Isso pode ser feito por meio da **Transformada de Fourier de Tempo Curto**



# Espectrograma



Eixo X: variáveis (energia/comprimento de onda)

Eixo Y: diferentes frequências que produziram os sinais ao longo do espectro

Intensidades das cores (eixo Z): Amplitude das frequências (intensidade)

**Intuição por traz da Transformada de Fourier**

# Intuição por traz da Transformada de Fourier

A ideia por traz da transformada de Fourier (FT) é fornecer uma ferramenta matemática capaz de decompor sinais (**espectros**) complexos em seus constituintes mais básicos (**frequências fundamentais**)

Como analogia, podemos pensar no processo de decomposição da luz por um prisma



# Intuição por traz da Transformada de Fourier

$$y_1 = 2\cos(t)$$



+

=




$$y_2 = 1\cos(2t)$$




$$y_3 = 1\cos(2t) + 2\cos(t) =$$

Domínio do tempo

FT



=



=



A magnitude/intensidade está relacionada com a amplitude do sinal básico

Domínio das frequências


1 Hz 2 Hz

**Frequência:** número de oscilações/repetições de um evento em um dado intervalo de tempo


Domínio do tempo



## Domínio temporal (original)




## Domínio das frequências



Domínio temporal (original)



Domínio das frequências



# Intuição por traz da Transformada de Fourier

A ideia é usar o fato de que qualquer sinal pode ser decomposto em uma soma de senos e cossenos (**série de Fourier**) com amplitudes e frequências específicas (**fundamentais**). A FT, portanto, extrai essas frequências fundamentais contabilizando os coeficientes da **série de Fourier**

Matematicamente, a **TF** de uma série temporal **contínua**  $x(t)$  é:


$$x(f) = \int_{-\infty}^{\infty} x(t) e^{-i2\pi f t} dt = \int_{-\infty}^{\infty} x(t) [\cos(2\pi f t) - i \sin(2\pi f t)] dt$$

Uma **série temporal** é a representação de uma sequência de observações tomadas em intervalos de tempo periódicos. Ex: medida da temperatura em um determinado local, de hora em hora. No nosso caso o “**tempo**” é a energia/comp de onda e temos a representação das contagens x intervalos de energia/comp de onda

# Transformada discreta de Fourier

$$x(f) = \int_{-\infty}^{\infty} x(t) e^{-i2\pi f t} dt = \int_{-\infty}^{\infty} x(t) [\cos(2\pi f t) - i \sin(2\pi f t)] dt$$


No contínuo, a TF integra  $x(t)$  sobre todo  $t$ . Entretanto, nossos dados são discretos no tempo (energia/comp de onda). Em outras palavras, nosso  $x(t)$  é discreto nos valores de  $t$ . Por isso precisamos da versão discreta da FT.



# Transformada discreta de Fourier

$$x(f) = \int_{-\infty}^{\infty} x(t) e^{-i2\pi f t} dt = \int_{-\infty}^{\infty} x(t) [\cos(2\pi f t) - i \sin(2\pi f t)] dt$$

No caso discreto, podemos discretizar o tempo em  $N$  intervalos  $\Delta t$ . Com amostragens em instantes  $t_n = n\Delta t$  só teremos valores pontuais  $x_n = x(t_n)$ . Logo, para cada amostra  $x_n$ :



$$x(f) = \sum_{n=0}^{N-1} x_n e^{-i2\pi f n \Delta t} ; n = 0, 1, \dots, N-1$$

$$x(k) = \sum_{n=0}^{N-1} x_n e^{-i2\pi \frac{kn}{N}}$$

# Transformada discreta de Fourier

$$x(\textcolor{red}{f}) = \int_{-\infty}^{\infty} x(t) e^{-i2\pi \textcolor{red}{f} t} dt$$

Caso contínuo

$$x(\textcolor{red}{k}) = \sum_{n=0}^{N-1} x_n e^{-i2\pi \frac{\textcolor{red}{k}n}{N}} \quad f_k = \frac{k}{N\Delta t}$$

Caso discreto  $t_n = n\Delta t$ ;  $n, k = 0, 1, \dots, N-1$

Como resultado, teremos as frequências  $\textcolor{red}{f}$  ou  $\textcolor{red}{f}_k$  com as quais  $x(t)$  ou  $x_n = x(t_n)$  podem ser decompostos, gerando os numeros complexos  $x(\textcolor{red}{f})$  ou  $x(\textcolor{red}{k})$  dos quais as intensidades (ou amplitudes) das frequências podem ser extraídas. Por exemplo, para o caso discreto temos:

$$x(k) = \sum_{n=0}^{N-1} x_n \cos\left(2\pi \frac{kn}{N}\right) - i \sum_{n=0}^{N-1} x_n \text{sen}\left(2\pi \frac{kn}{N}\right)$$

$$Z = a + ib$$

$$a = \text{Re}(Z)$$

$$b = \text{Im}(Z)$$

# Transformada discreta de Fourier

$$x(\textcolor{red}{f}) = \int_{-\infty}^{\infty} x(t) e^{-i2\pi \textcolor{red}{f} t} dt$$

Caso contínuo

$$x(\textcolor{red}{k}) = \sum_{n=0}^{N-1} x_n e^{-i2\pi \frac{\textcolor{red}{k}n}{N}} \quad f_k = \frac{k}{N\Delta t}$$

Caso discreto  $t_n = n\Delta t$ ;  $n, k = 0, 1, \dots, N-1$


Como resultado, teremos as frequências  $\textcolor{red}{f}$  ou  $\textcolor{red}{f}_k$  com as quais  $x(t)$  ou  $x_n = x(t_n)$  podem ser decompostos, gerando os números complexos  $x(\textcolor{red}{f})$  ou  $x(\textcolor{red}{k})$  dos quais as intensidades (ou amplitudes) das frequências podem ser extraídas. Por exemplo, para o caso discreto temos:

$$|Z| = \sqrt{a^2 + b^2} \quad I_k = |x(k)| = \sqrt{\left[ \sum_{n=0}^{N-1} x_n \cos\left(2\pi \frac{kn}{N}\right) \right]^2 + \left[ \sum_{n=0}^{N-1} x_n \sin\left(2\pi \frac{kn}{N}\right) \right]^2}$$

# Transformada discreta de Fourier

$$x(k) = \sum_{n=0}^{N-1} x(t_n) e^{-i2\pi \frac{kn}{N}}$$
$$f_k = \frac{k}{N\Delta t} \quad I_k = |x(k)|$$
$$t_n = n\Delta t; \quad n, k = 0, 1, \dots, N-1$$

Portanto, teremos um **vetor 1D** cujos coeficientes são **amplitudes de frequências** ( $I_k$ ) presentes no sinal original em função das  $f_k$  frequências





# Simetria hermitiana

Por outro lado, devido a natureza subjacente dos números complexos, existe uma redundância nas respostas da FFT. É a chamada **simetria hermitiana**

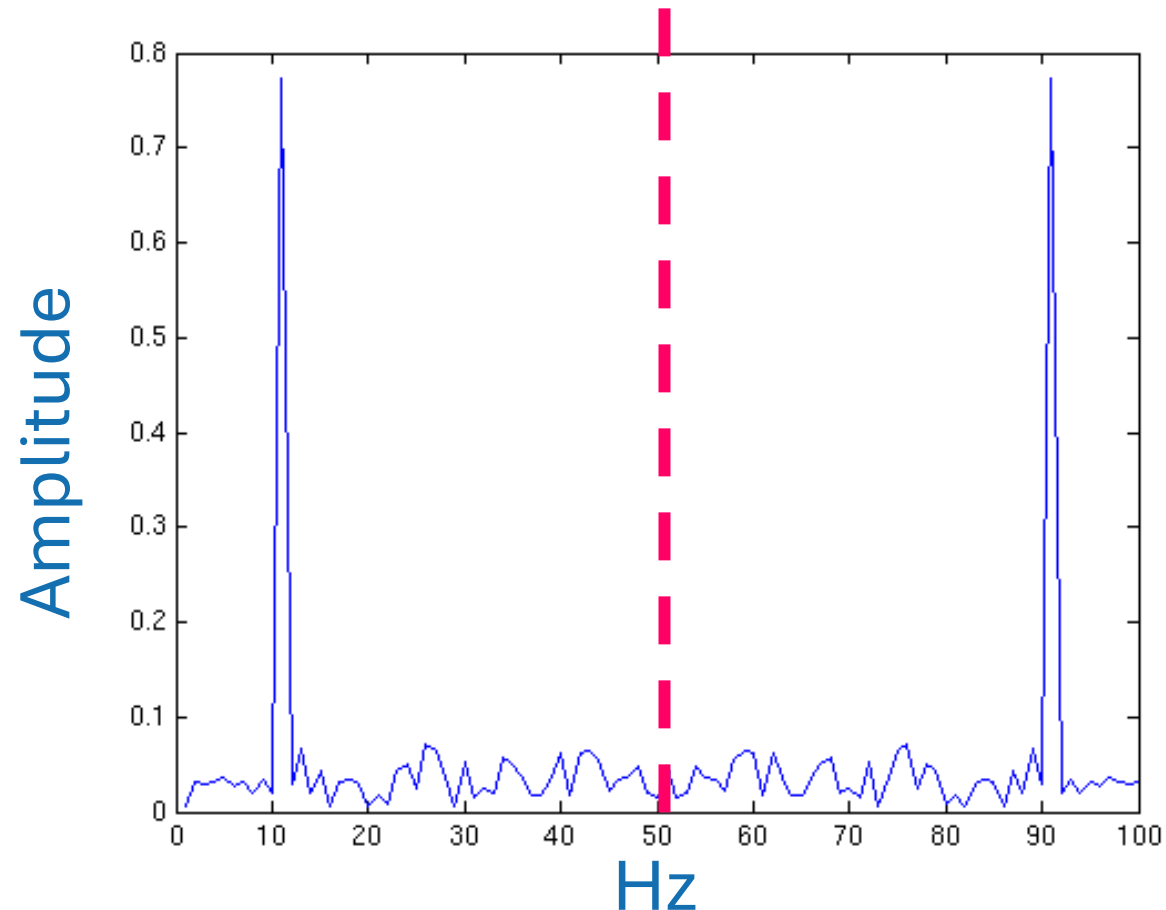
$$x(N - k) = \sum_{n=0}^{N-1} x(t_n) e^{-i \frac{2\pi n}{N} (N-k)} = \sum_{n=0}^{N-1} x(t_n) e^{-i \frac{2\pi n}{N} N} e^{i \frac{2\pi n}{N} k}$$

$$x(N - k) = \sum_{n=0}^{N-1} x(t_n) e^{-i 2\pi n} e^{i \frac{2\pi n}{N} k} \quad e^{-i 2\pi n} = \cos(2\pi n) - i \sin(2\pi n) = 1$$

$$x(N - k) = \sum_{n=0}^{N-1} x(t_n) e^{i \frac{2\pi n}{N} k} = \overline{x(k)} \overline{x(k)} = \sum_{n=0}^{N-1} x(t_n) e^{+i \frac{2\pi n}{N} k}$$

# Simetria hermitiana

Portanto  $x(N - k) = \overline{x(k)}$ , isso acarreta que em algum  $k$  os valores de frequência começarão a assumir valores equivalentes aos complexo conjugados daqueles que vieram anteriormente. Como a amplitude de frequência não é afetada pelo sinal da parte imaginária de  $x(k)$ , existirá um  $k$  “espelho” que repetirá valores



# Simetria hermitiana

$$f_k = \frac{k}{N\Delta t} \quad k = 0, 1, \dots, N-1 \quad f_{N-1} = \frac{(N-1)}{N\Delta t}$$

$$x(k + pN) = \sum_{n=0}^{N-1} x(t_n) e^{-i\frac{2\pi n}{N}(k+pN)} \quad p = 0, 1, 2, 3, \dots$$

$$x(k + pN) = \sum_{n=0}^{N-1} x(t_n) e^{-i\frac{2\pi n}{N}k} e^{-i\frac{2\pi n}{N}Np} \quad e^{-i2\pi np} = \cos(2\pi np) - i\sin(2\pi np)$$
$$e^{-i2\pi np} = 1$$

$$x(k + pN) = \sum_{n=0}^{N-1} x(t_n) e^{-i\frac{2\pi n}{N}k} = x(k)$$


Ou seja, a FFT é periódica com relação a múltiplos inteiros de N

# Simetria hermitiana

Logo, se a FFT é periódica com relação a múltiplos inteiros de  $N$ , e tem simetria hermitiana, o eixo de simetria só pode ocorrer na frequência cujo  $k = N/2$


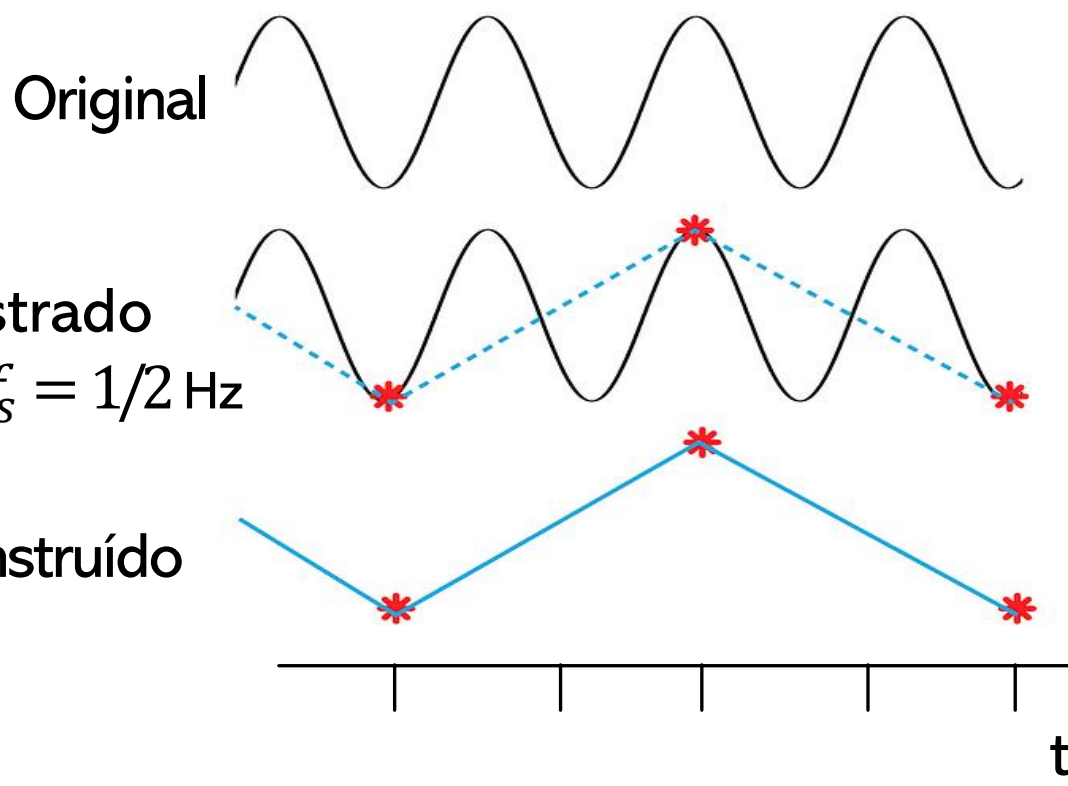
$$f_{N/2} = \frac{1}{N\Delta t} \frac{N}{2} = \frac{1}{2\Delta t}$$

Essa é a chamada frequência  
(ou taxa) de *Nyquist*




# Frequência de amostragem

Definindo  $f_s \equiv 1/\Delta t$  como a frequência de amostragem (*sampling frequency*), ou seja, o número de amostras coletadas por unidade de tempo (variáveis = energia/comp de onda), temos um parâmetro relacionado com a **resolução** com a qual o sinal base vai ser reconstruído discretamente




# Transformada discreta de Fourier



Logo, a taxa de amostragem é um valor crucial para a FT reconstruir o sinal adequadamente, e assim extrair as frequências da melhor forma possível. O valor mínimo recomendado é  $2 \times \text{frequência original}$ . Ex: para sinais gerados via **60 Hz**, o mínimo para uma boa reconstrução via FT é um  $f_s$  de **120 Hz**

# Transformada discreta de Fourier



Logo,  $f_s \geq 2 \times f_0$  para uma boa reconstrução do sinal e consequentemente bons resultados via FT (livres de distorções). Para sinais com múltiplas frequências (como os espectros), devemos considerar a maior frequência entre todas como o  $f_0$

# Transformada Rápida de Fourier

A Transformada Rápida de Fourier (FFT) é um algoritmo eficiente para calcular a Transformada Discreta de Fourier (DFT), permitindo a análise de sinais no domínio da frequência com menor complexidade computacional e maior rapidez

A ideia do algoritmo baseia-se no chamado método de dobramentos sucessivo

a Transformada discreta de Fourier de  $n$  pontos da maneira ingênua, usando a definição, leva operações aritméticas de  $O(N^2)$ , enquanto uma Transformada rápida de Fourier pode computar a mesma Transformada discreta de Fourier em apenas  $O(N * \log N)$

Os resultados obtidos seja via transformada original seja via transformada rápida são essencialmente os mesmos, diferindo muito pouco



# FFT de Tempo Curto

A Transformada de Fourier tradicional decompõe um sinal em suas componentes de frequência, assumindo que essas componentes **são constantes ao longo do tempo** (**sinal estacionário**). No entanto, muitos sinais do mundo real são **não estacionários**, ou seja, suas propriedades espectrais variam ao longo do tempo ou da energia/comprimento de onda (**XRF, vis-NIR, etc...**)


Para esse tipo de dataset, a transformada discreta (ou rápida) de Fourier de **Tempo Curto** (**STFFT**) é mais adequada.

A ideia é particionar o espectro original em **intervalos menores**, em janelas de “**tempo curto**”, de forma que os sinais possam ser considerado **constante no seu interior**, e aplicar a **FFT** em cada um deles. Aqui temos o conceito de janela deslizando (semelhante ao processo de **convolução unidimensional** das redes neurais convolucionais)

# FFT de Tempo Curto


Em outras palavras, enquanto a **FFT** nos fornece **QUAIS** são as frequências base que construíram o nosso sinal, não dá pra saber **QUANDO**. Por isso precisamos quebrar a **FFT** em pequenos intervalos de tempo (energia/comp de onda) para saber em **QUAIS** intervalos tal frequência estava **MAIS** ou **MENOS** presente, permitindo assim avaliar a sua **VARIAÇÃO**.

Portanto, consideramos o sinal original em vários **segmentos** (ou **frames**) e aplicamos a **FFT** **localmente**.



A técnica de **janelamento** é aplicada a cada segmento antes de passar pela FFT

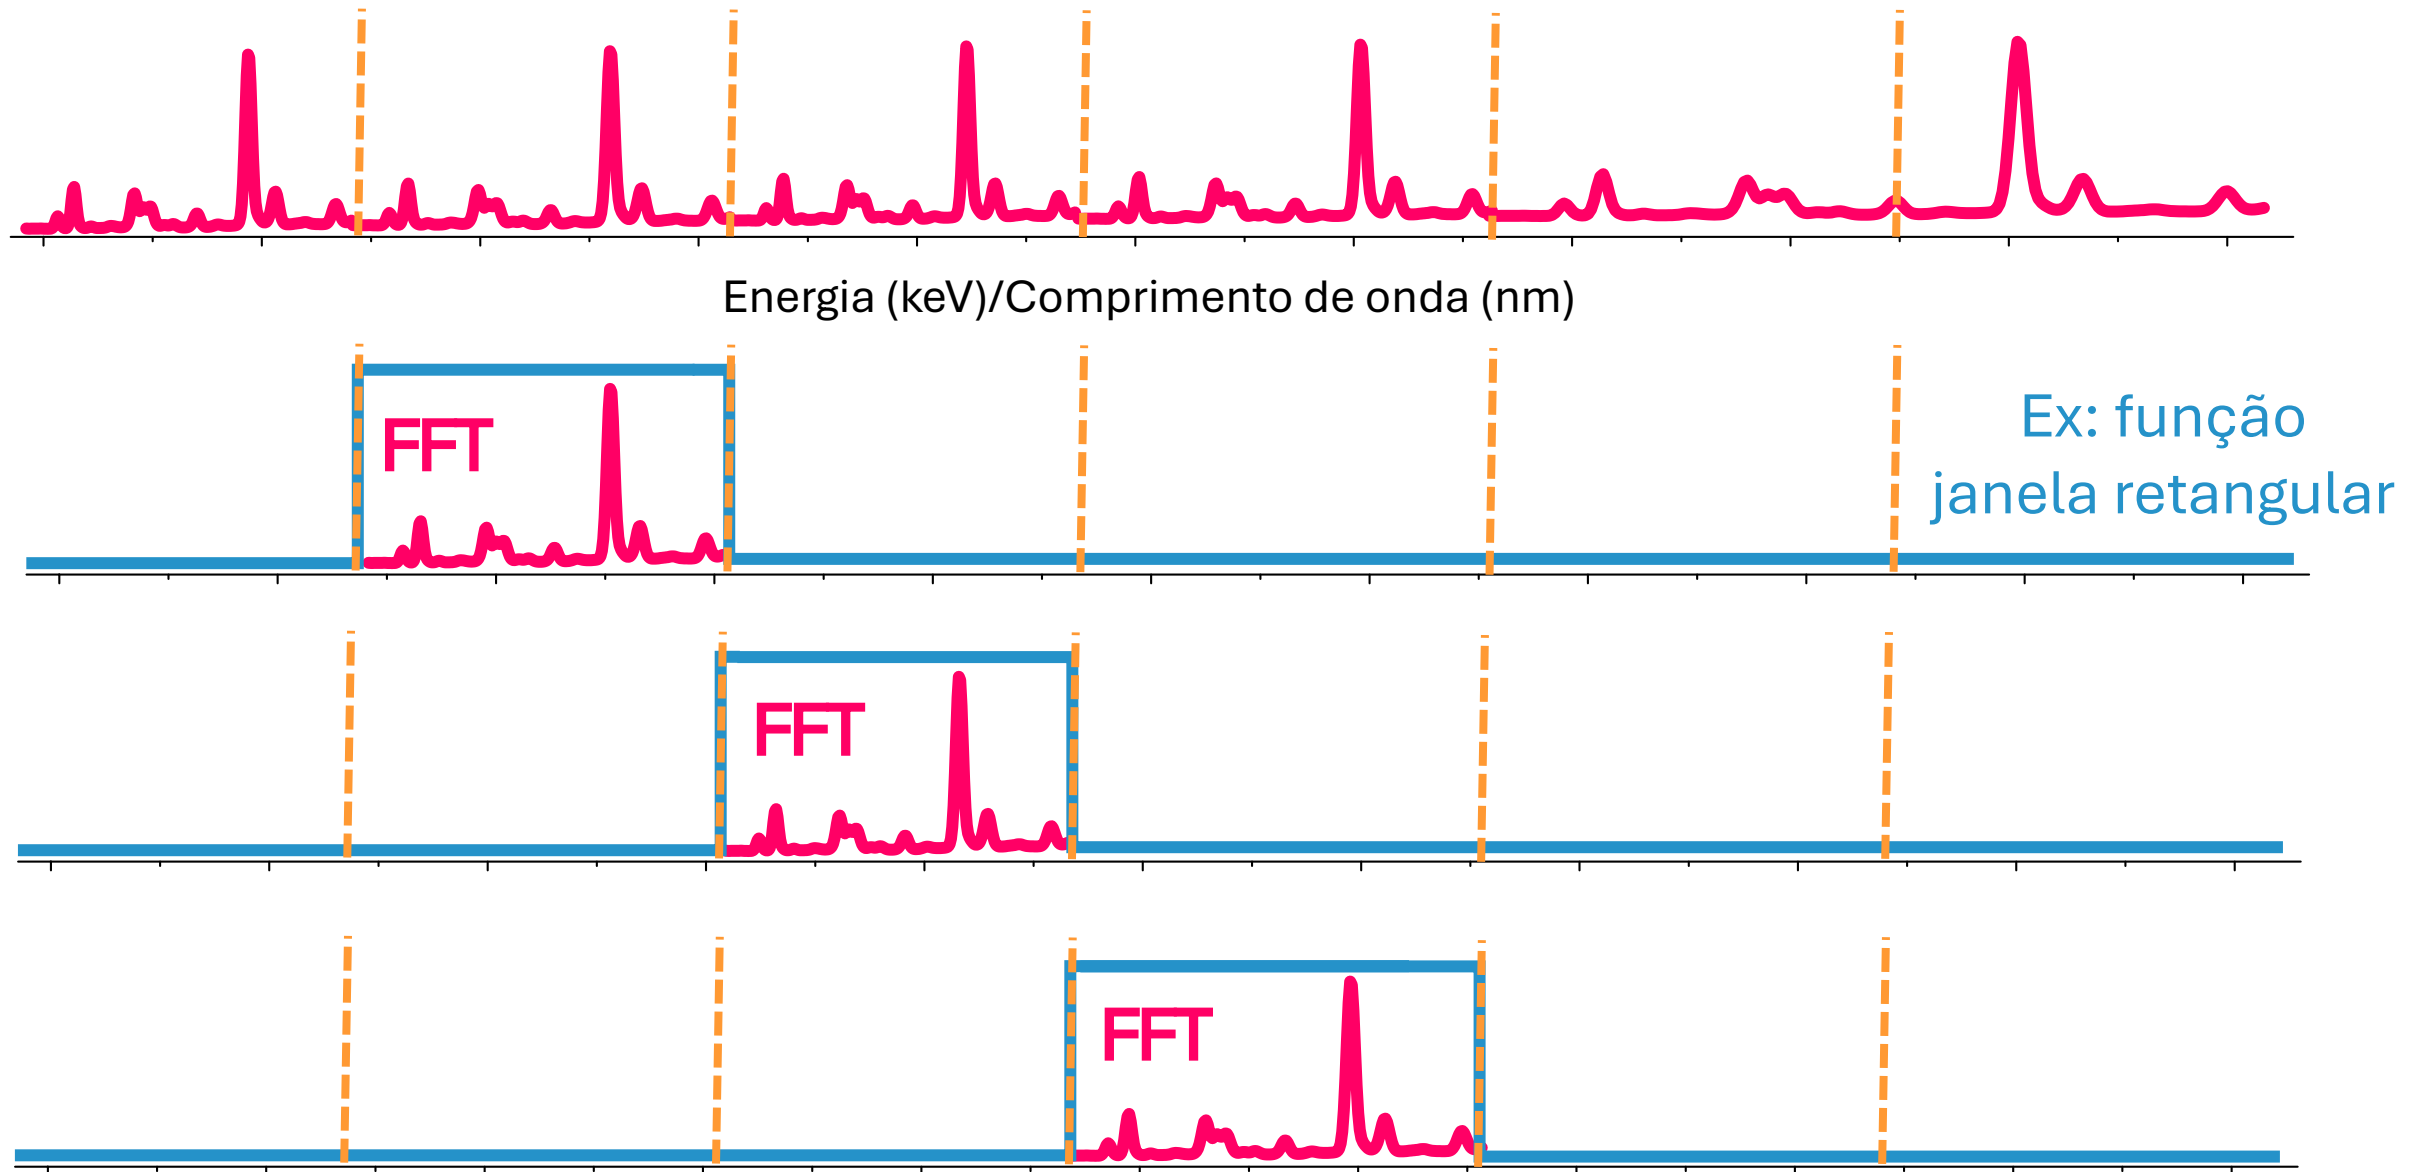
# Técnica de janelamento



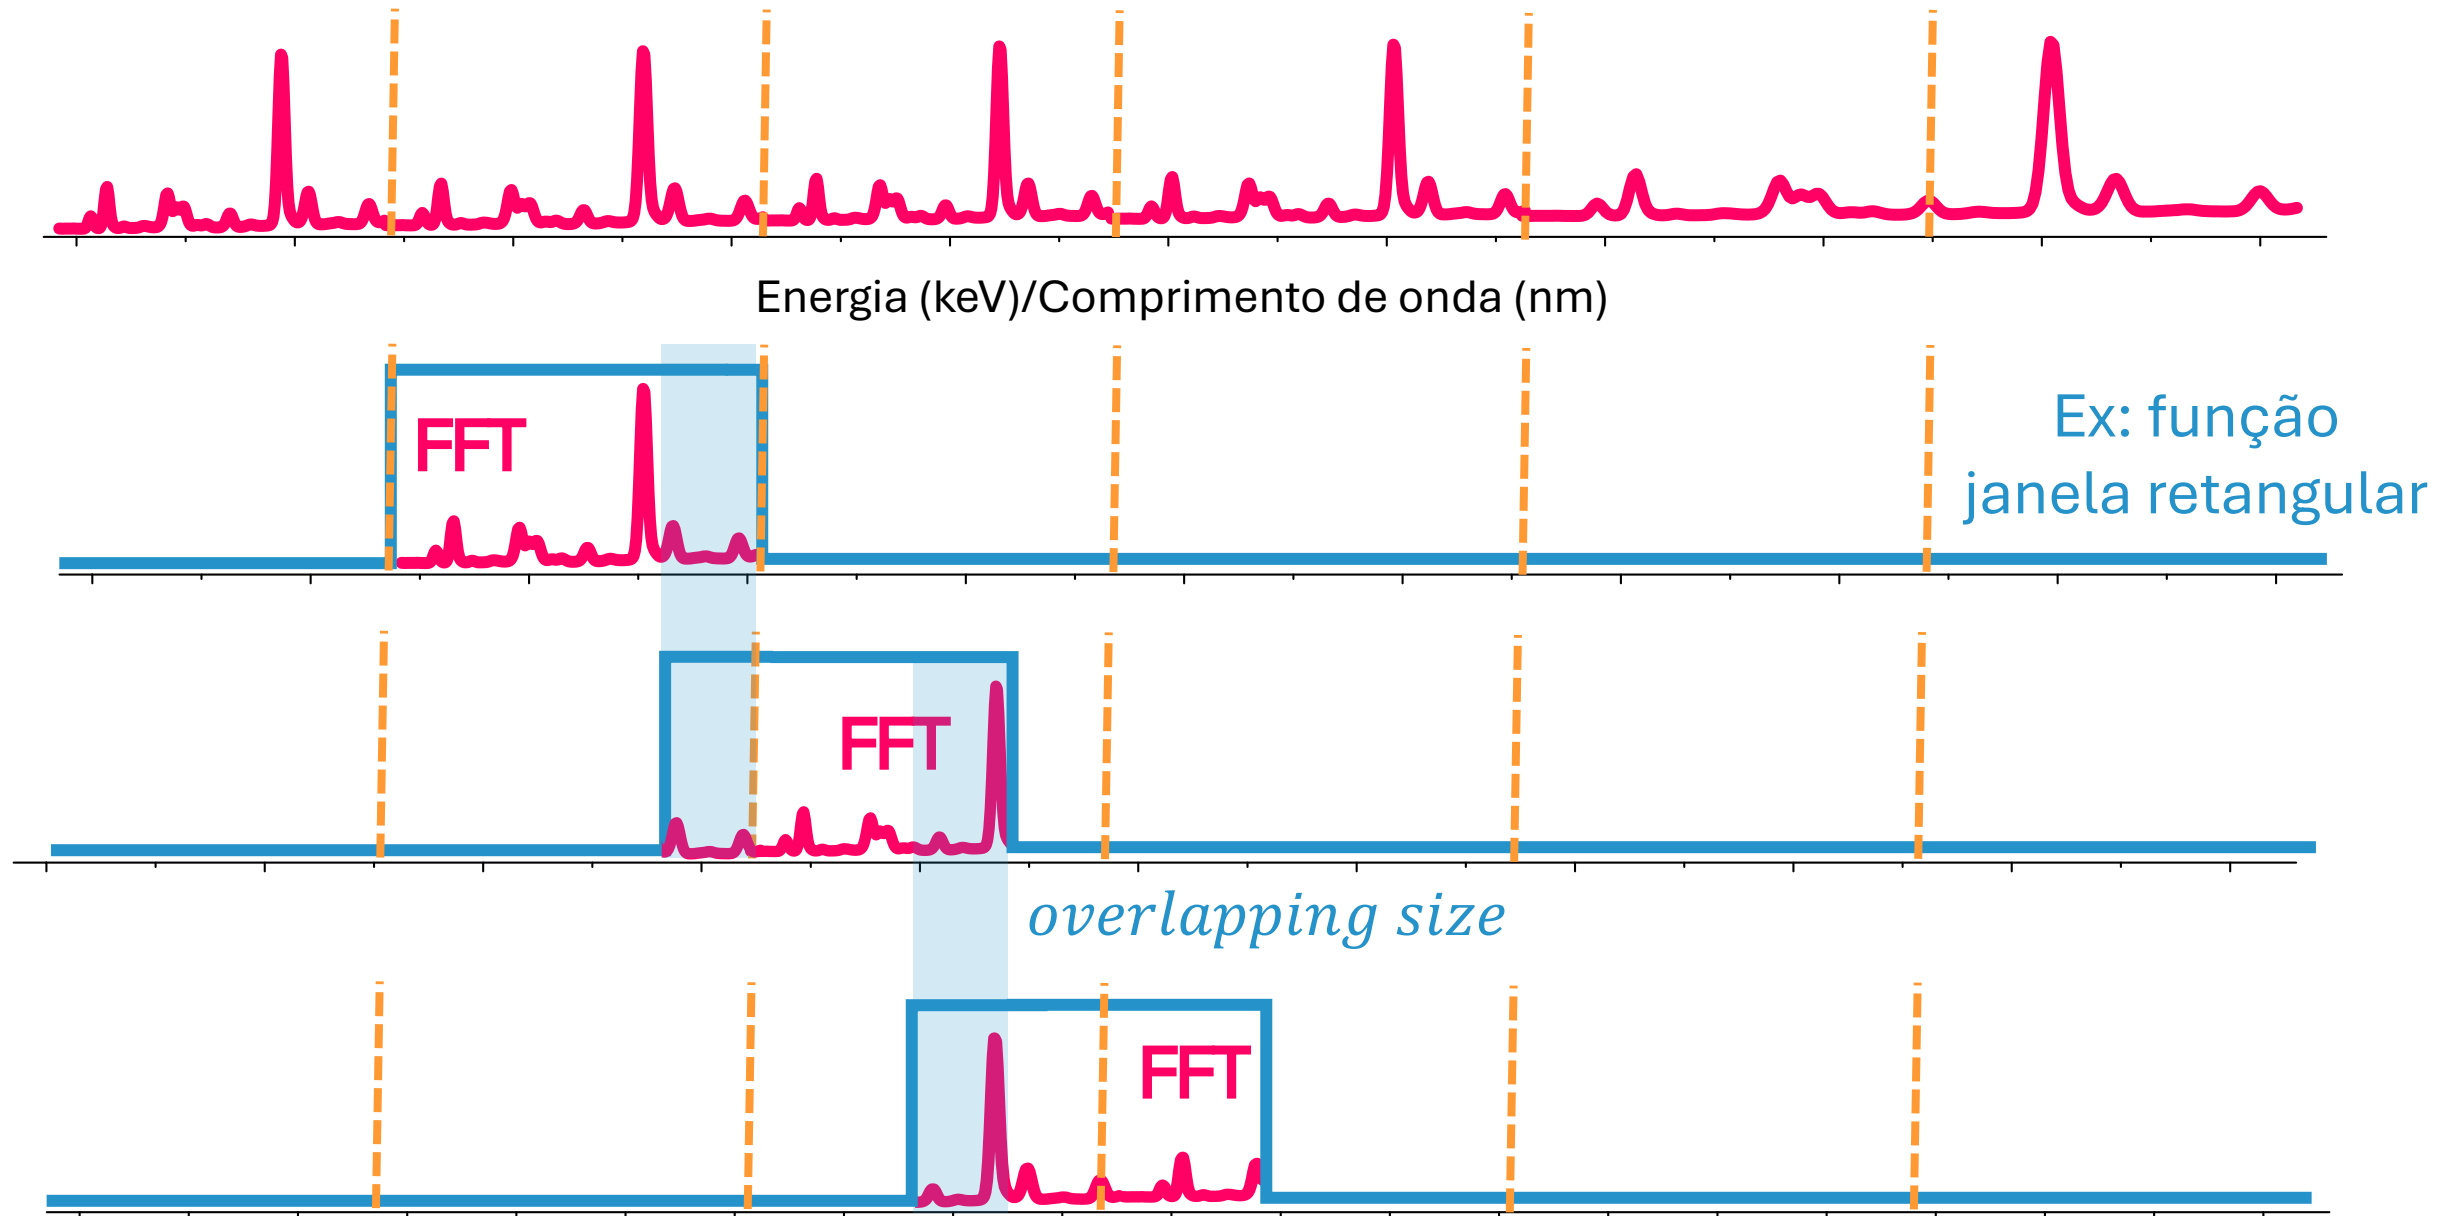
O *window size* representa o numero de canais que vão ser amostrados na janela

Já o **frame size** é o numero de canais que vão ser amostrados em cada segmento passado para a FFT de tempo curto (ele é definido primeiro). **Usualmente eles são iguais**

# Técnica de janelamento

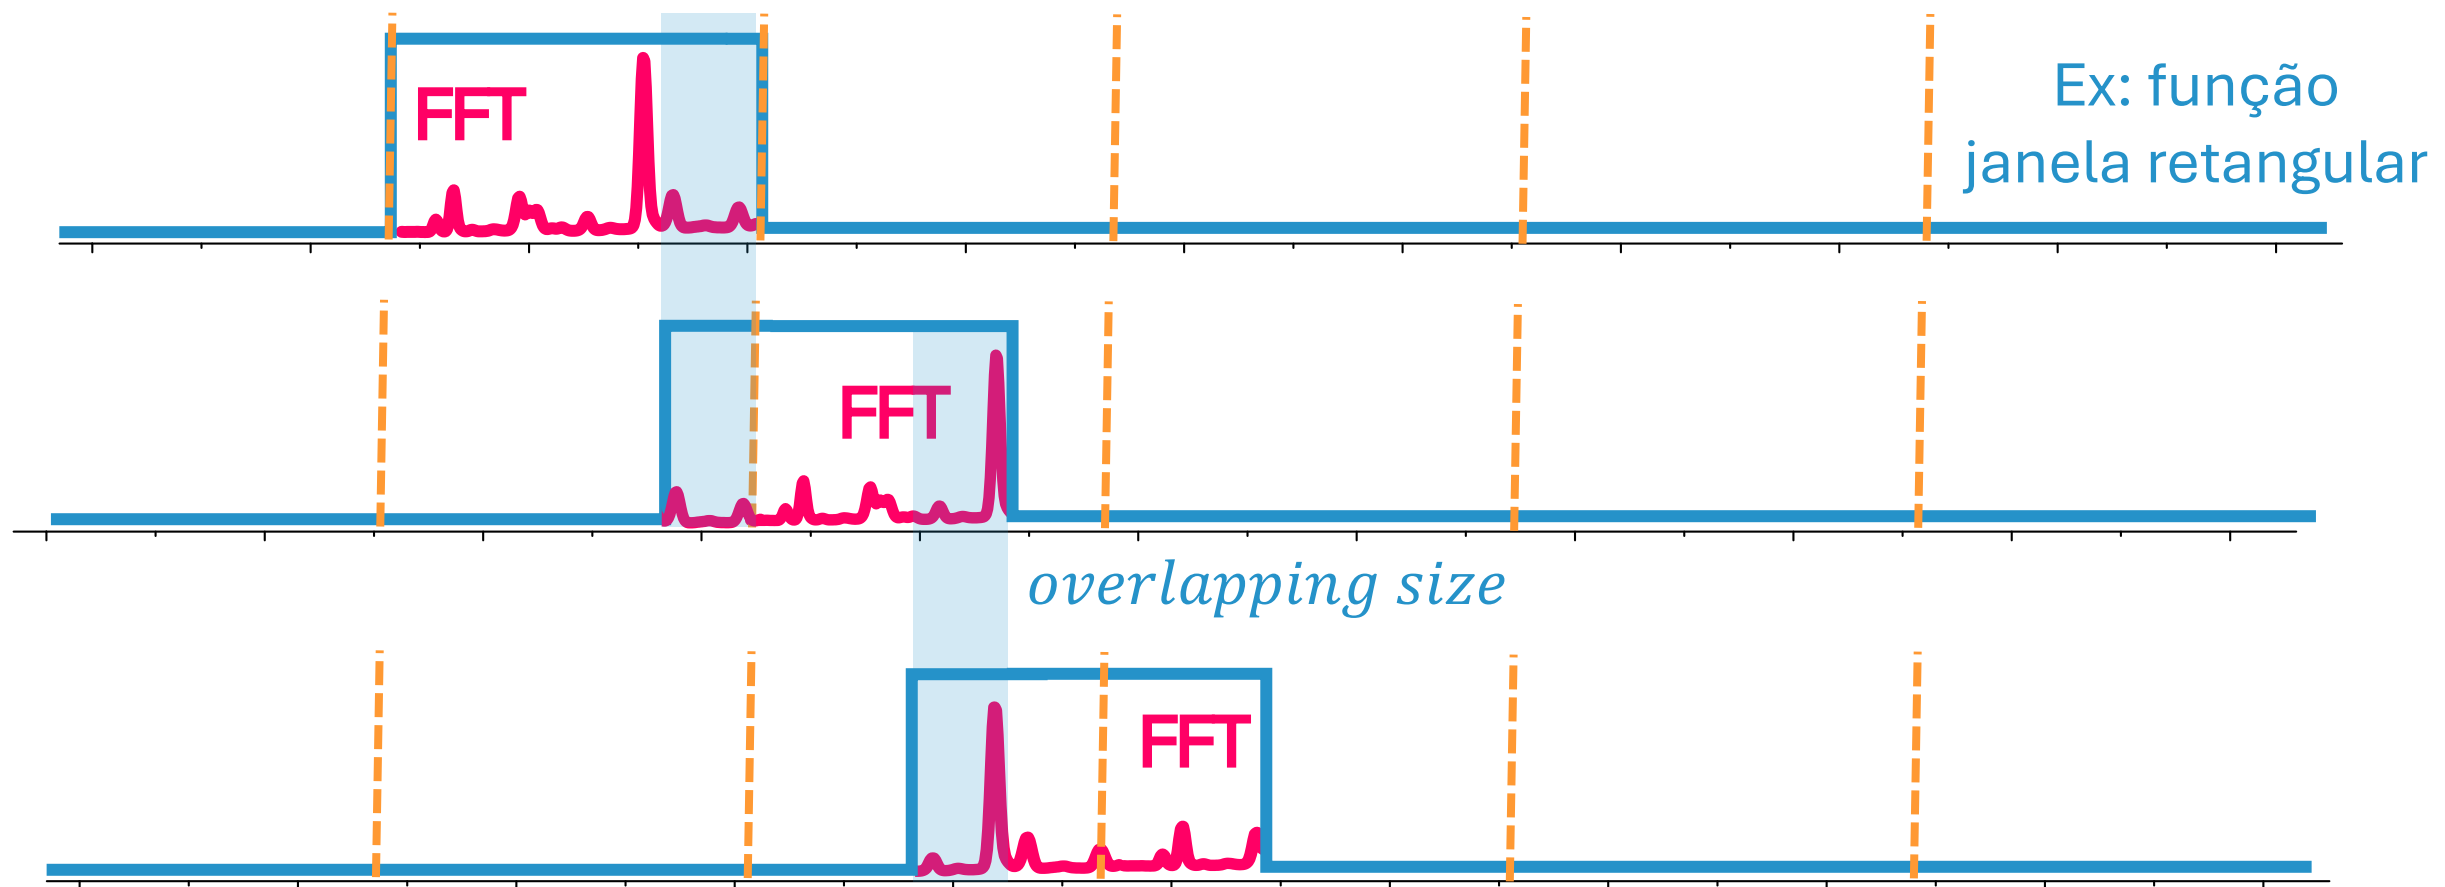


# Técnica de janelamento - sobreposição

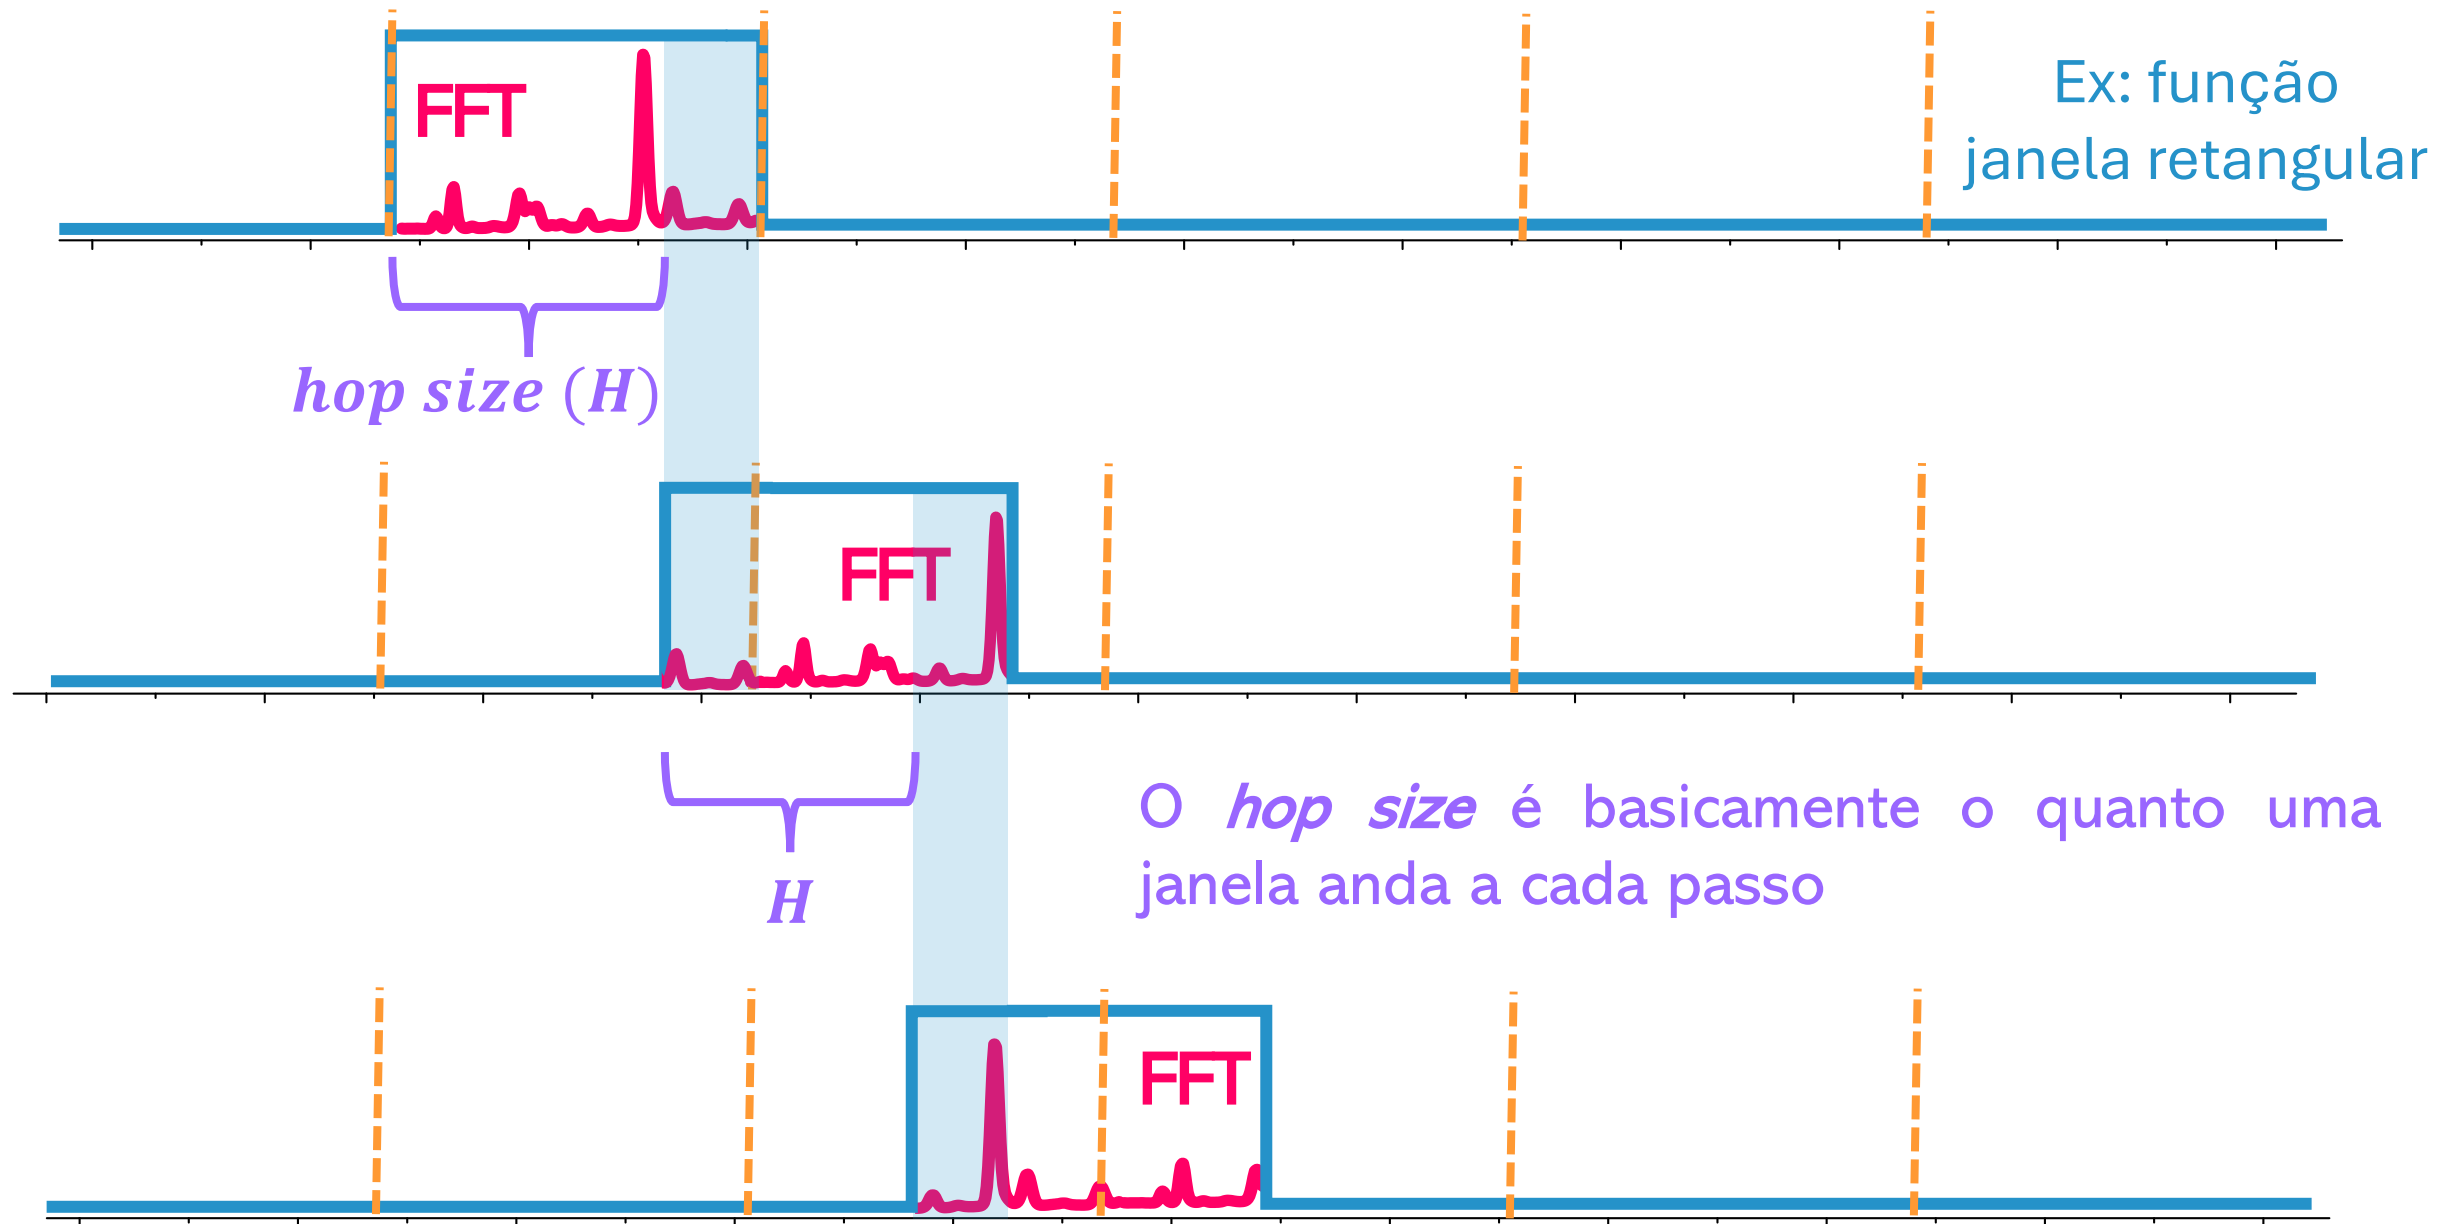


# Técnica de janelamento - sobreposição

A sobreposição ajuda a capturar transições suaves no sinal entre uma janela e outra. Ela é usada para garantir que não haja “buracos” na cobertura do espectro quando a janela “desliza”



# Técnica de janelamento - sobreposição



# De FFT para STFFT

Transformada Discreta  
(sinal estacionário)

$$x(k) = \sum_{n=0}^{N-1} x(n) e^{-i2\pi n \frac{k}{N}}$$

$$t_n = n\Delta t; \quad n, k = 0, 1, \dots, N-1$$

$$x_n = x(t_n) = x(n)$$

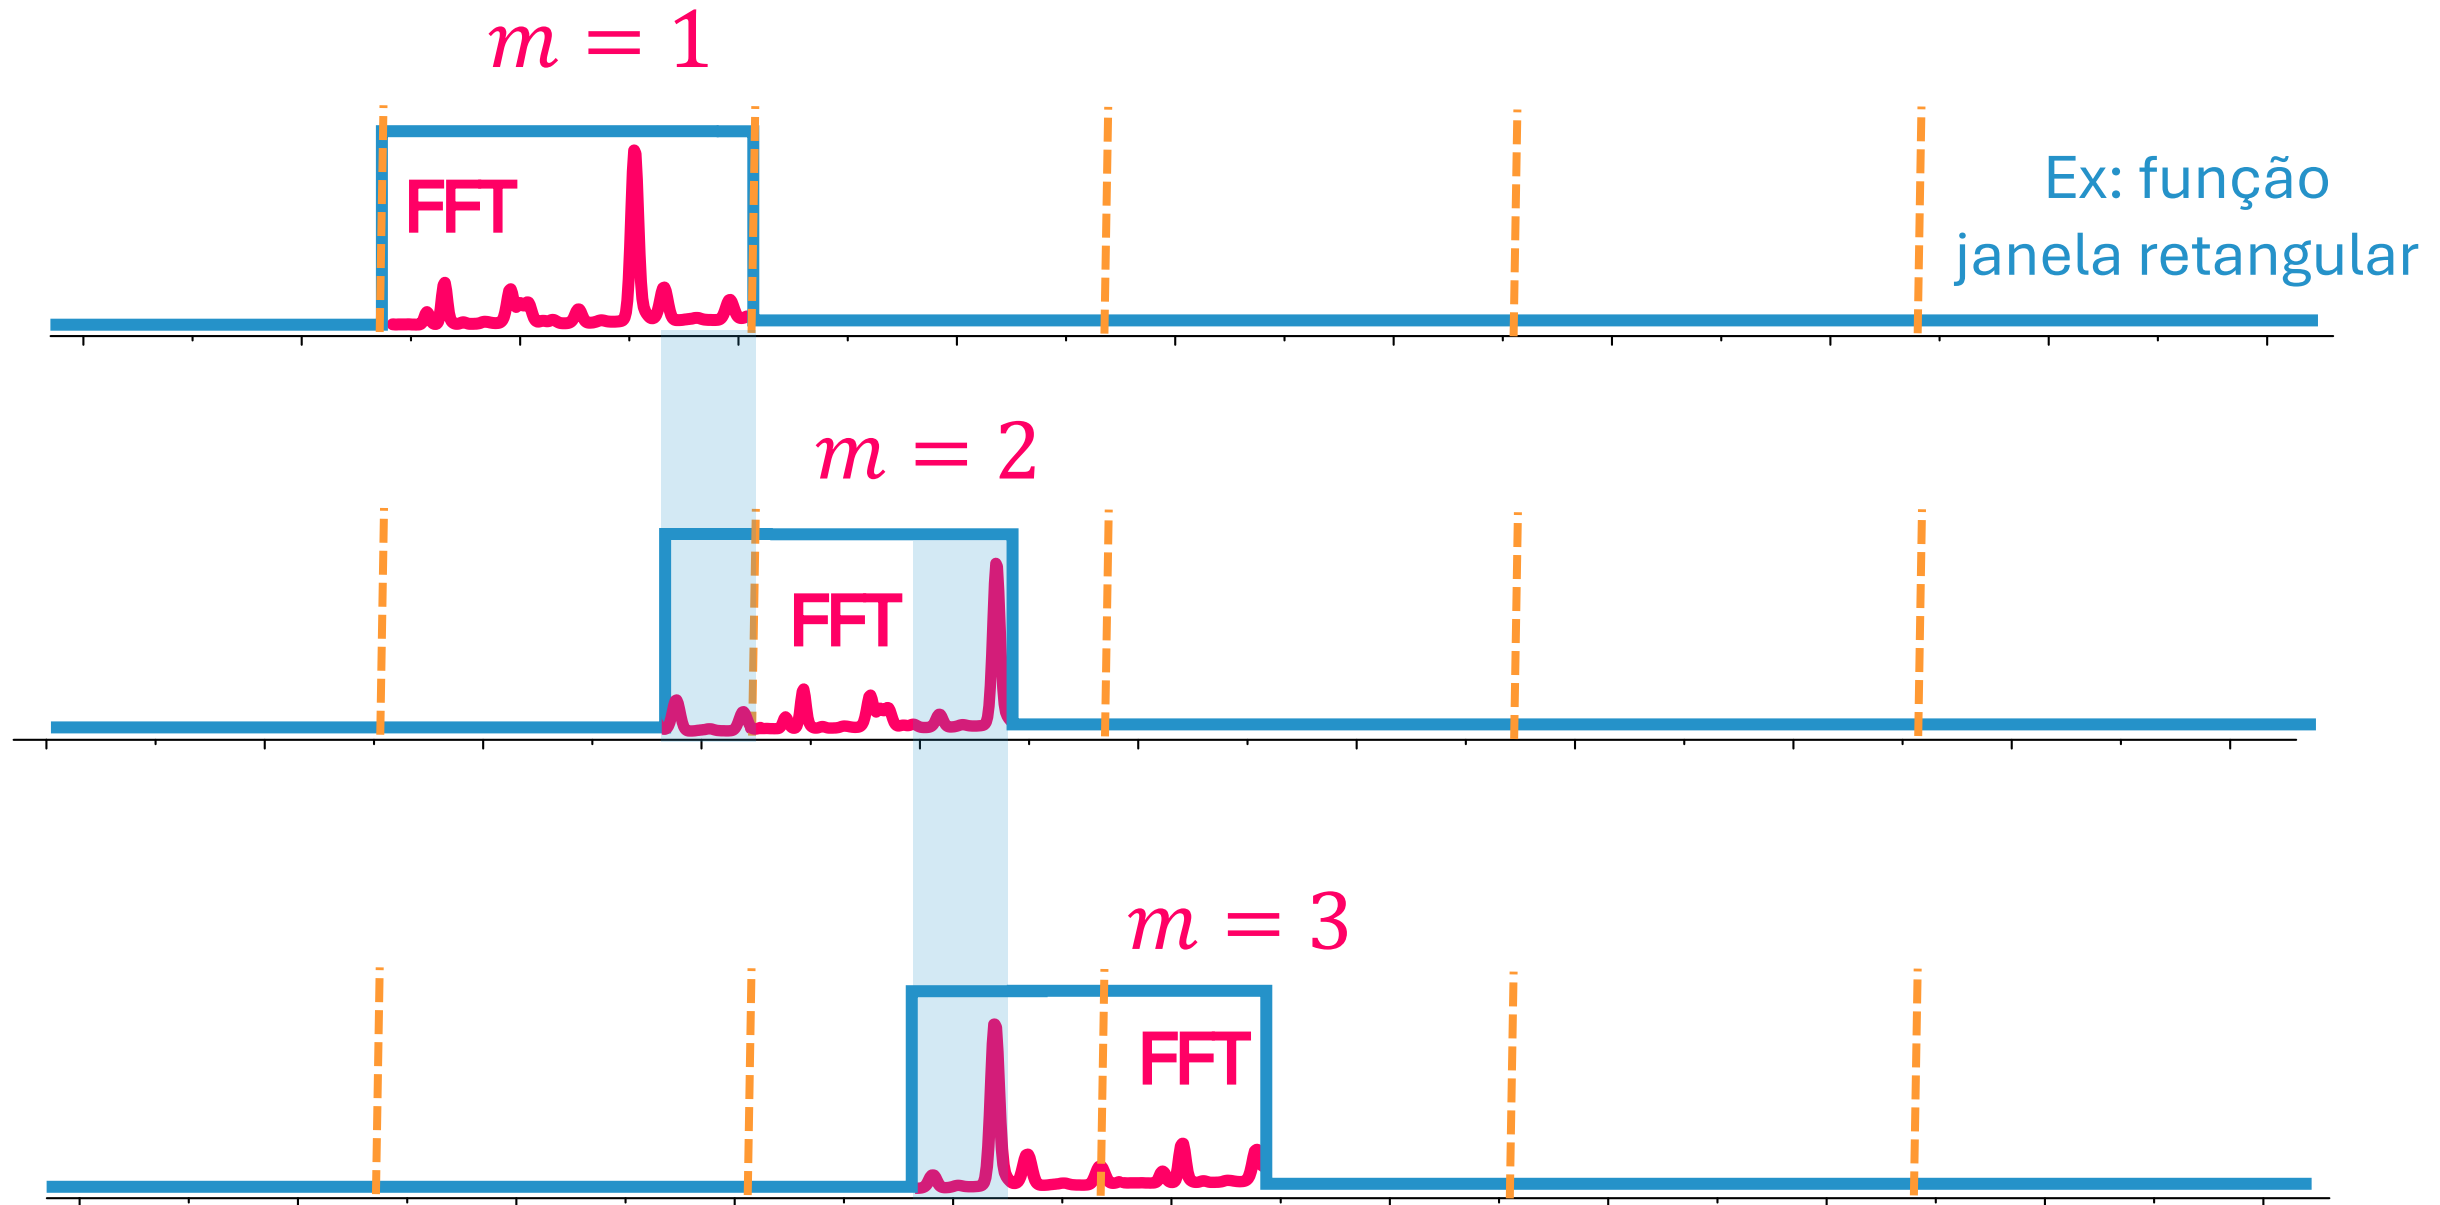
Transformada Discreta de Tempo Curto  
(sinal não-estacionário)

$$x(k, m) = \sum_{n=0}^{N-1} x(n + mH) w(n) e^{-i2\pi n \frac{k}{N}}$$

O  $m$  representa o frame (segmento) no qual a transformada está atuando no momento



# De FFT para STFFT



# De FFT para STFFT

Transformada Discreta  
(sinal estacionário)

$$x(k) = \sum_{n=0}^{N-1} x(n) e^{-i2\pi n \frac{k}{N}}$$

$$t_n = n\Delta t; \quad n, k = 0, 1, \dots, N-1$$

$$x_n = x(t_n) = x(n)$$

Transformada Discreta de Tempo Curto  
(sinal não-estacionário)

$$x(k, m) = \sum_{n=0}^{N-1} x(n + mH) w(n) e^{-i2\pi n \frac{k f_s}{N}}$$

A resposta da transformada vai ser a  $k$  —ésima amplitude de frequência do  $m$  —ésimo frame (segmento)

# De FFT para STFFT

Transformada Discreta  
(sinal estacionário)

$$x(k) = \sum_{n=0}^{N-1} x(n) e^{-i2\pi n \frac{k}{N}}$$

$$t_n = n\Delta t; \quad n, k = 0, 1, \dots, N-1$$

$$x_n = x(t_n) = x(n)$$

Transformada Discreta de Tempo Curto  
(sinal não-estacionário)

$$x(k, m) = \sum_{n=0}^{N-1} x(n + mH) w(n) e^{-i2\pi n \frac{k}{N}}$$

O  $N$  na transformada de tempo curto representa todas as amostras existentes em CADA frame (segmento), não mais todos os pontos do dataset. Já o  $n$  denota o  $n$ -ésimo ponto existente neste frame

# De FFT para STFFT

Transformada Discreta  
(sinal estacionário)

$$x(k) = \sum_{n=0}^{N-1} x(n) e^{-i2\pi n \frac{k}{N}}$$

$$t_n = n\Delta t; \quad n, k = 0, 1, \dots, N-1$$


$$x_n = x(t_n) = x(n)$$

Transformada Discreta de Tempo Curto  
(sinal não-estacionário)

$$x(k, m) = \sum_{n=0}^{N-1} x(n + mH) w(n) e^{-i2\pi n \frac{k f_s}{N}}$$

Já o termo  $x(n + mH)$  indica que estamos somando sobre todos os pontos ( $n$ ) do sinal presentes no  $m$ -ésimo frame (segmento) específico

# Técnica de janelamento - sobreposição



$$x(k, m) = \sum_{n=0}^{N-1} x(n + mH)w(n)e^{-i2\pi n \frac{kf_s}{N}}$$

Perceba que se  $n$  denota os pontos coletados dentro de cada frame (segmento),  $mH$  indica a primeira amostra em cada frame. Logo, a medida que  $m$  varia temos a ideia de passo deslizante sobre os frames no qual vamos somando sobre todos os  $n$  pontos existentes

# De FFT para STFFT

Transformada Discreta  
(sinal estacionário)

$$x(k) = \sum_{n=0}^{N-1} x(n) e^{-i2\pi n \frac{k}{N}}$$

$$t_n = n\Delta t; \quad n, k = 0, 1, \dots, N-1$$

$$x_n = x(t_n) = x(n)$$

Transformada Discreta de Tempo Curto  
(sinal não-estacionário)

$$x(k, m) = \sum_{n=0}^{N-1} x(n + mH) w(n) e^{-i2\pi n \frac{k f_s}{N}}$$

O termo  $w(n)$  corresponde a janela que será aplicada em cada frame, englobando todos  $n$ -pontos presentes

# FFT de Tempo Curto - Janelas

A janela retangular é só para exemplificar. Na verdade as principais janelas utilizadas são mais sofisticadas:

$$w(n) = 0.5 - 0.5\cos\left(\frac{2\pi n}{N-1}\right)$$

Janela de Hann

$$0 \leq n \leq N-1; \quad w(0) = w(N-1) = 0$$

$$w(n) = 0.54 - 0.46\cos\left(\frac{2\pi n}{N-1}\right)$$


Janela de  
Hamming

$$0 \leq n \leq N-1; \quad w(0) = w(N-1) \neq 0.$$


$$w(n) = 0.5 - 0.5\cos\left(\frac{2\pi n}{N-1}\right)$$

Janela de Hann

$$0 \leq n \leq N-1; \quad w(0) = w(N-1) = 0$$








# FFT de Tempo Curto

Diferença nos resultados gerados:


Na FFT normal, temos como resposta um **vetor 1D** que tem como coeficientes as **amplitudes de frequências** presentes no sinal original, sem fazer menção a sua variação ao longo do tempo (energia/comp de onda)



# FFT de Tempo Curto


Diferença nos resultados gerados:

Já na STFFT temos como resposta o mesmo vetor 1D, porém, um para cada frame (segmento). Isso gera uma **matriz 2D** com amplitudes de frequências (**frequency bins**) versus os **frames (variável temporal)**, fornecendo **como elas variam** ao longo do tempo ou das variáveis adotadas (energia/comp de onda)




# FFT de Tempo Curto


Diferença nos resultados gerados:



Domínio do tempo



Domínio da frequência  
(FFT)



Short Time FFT

# Dimensão das respostas da STFFT

$$\# \text{ frequency bins} = \frac{\text{frame size}}{2} + 1$$

Número de pontos incluídos dentro de cada frame (segmento)

Numero de faixas de frequência englobadas ao longo da STFFT

$$\# \text{ frames} = \frac{\text{variables} - \text{frame size}}{\text{hop size}} + 1$$

O numero de variáveis. É como o numero total de “pontos” medidos

O quanto a janela anda a cada passo

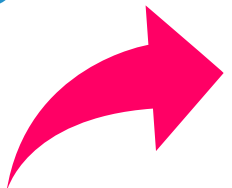
# Dimensão das respostas da STFFT

Ex: Um sinal amostrado em 10000 intervalos de tempo (variáveis) cujo o qual aplicamos a STFFT com frame size = 1000 e hop size = 500 gera uma matriz 2D de dimensões:

$$\# \text{ frequency bins} = \frac{1000}{2} + 1 = 501 \quad \rightarrow \quad \left[0, f_s/2\right] \quad f_s = 205.5 \text{ Hz}$$

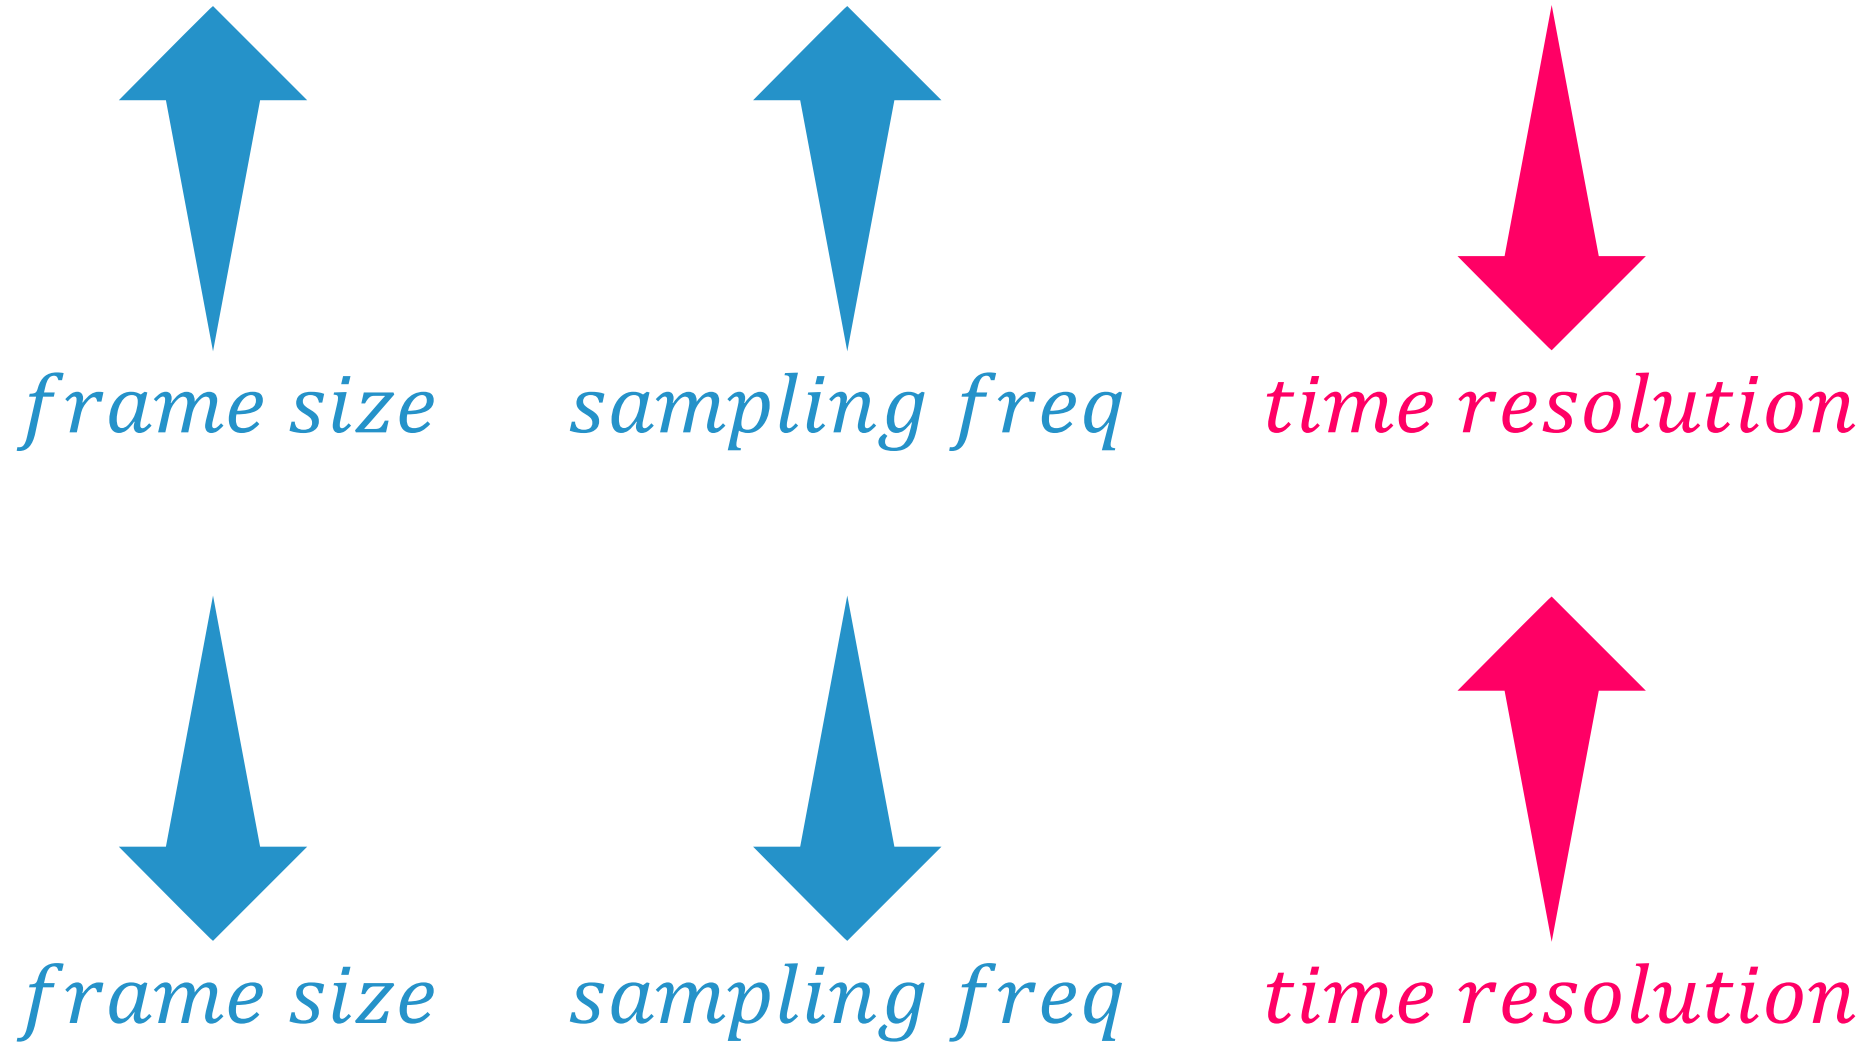
$$\# \text{ frames} = \frac{10000 - 1000}{500} + 1 = 19$$

$$[ST]_{501 \times 19} = \begin{bmatrix} ST_{1 \times 1} & \cdots & ST_{1 \times 19} \\ \vdots & \ddots & \vdots \\ ST_{501 \times 1} & \cdots & ST_{501 \times 19} \end{bmatrix}$$

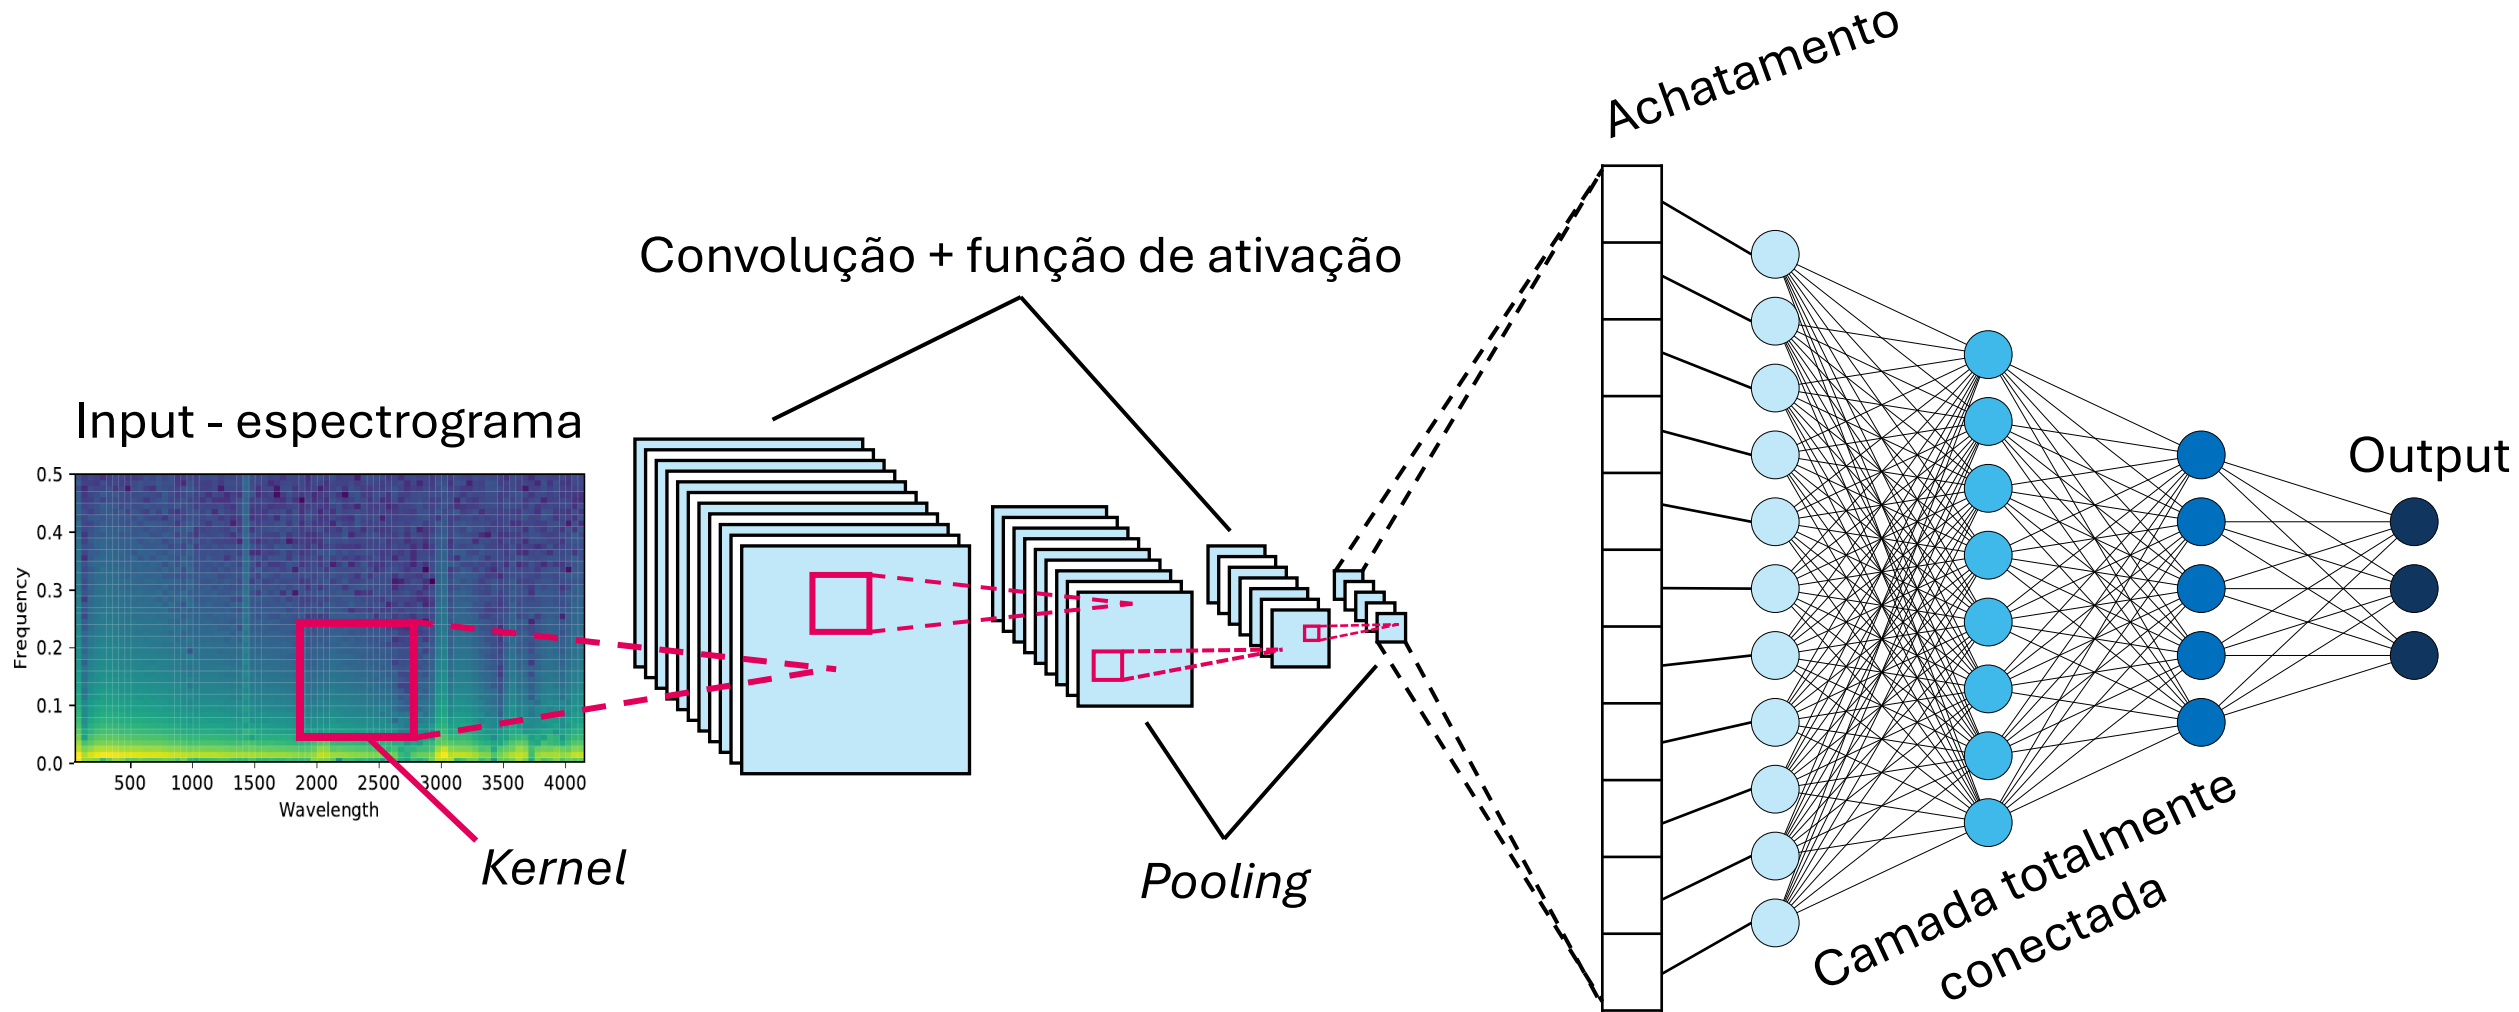


O componente da  $i$ -ésima linha carrega as intensidades das frequências (decompostas em 501 intervalos) presentes no respectivo  $i$ -ésimo frame

# Time / Frequency trade off




# CNN 2D - espectrogramas






# Funções de ativação Leaky e Parametric ReLU



ReLU



Leaky ReLU


# Funções de ativação Leaky e Parametric ReLU

## Parametric ReLU - PReLU

$$f(y_i) = y_i, \quad \forall y_i \geq 0$$

Introduz um parâmetro aprendível  $\alpha_i$  para controlar a inclinação da parte negativa da função. A camada PReLU aprende um  $\alpha$  distinto para cada elemento da entrada

$$f(y_i) = \alpha_i y_i, \quad \forall y_i < 0$$



# PRÁTICA – GOOGLE COLAB